


OPEN SOURCE · WHITELABEL **DEMNÄCHST**

Die selbstlernende Context-Layer für Fonds.

Unter jedem Agenten, jedem Portal, jedem Report liegt dieselbe Frage: Woher weiß das System, was gilt? Diese Schicht antwortet darauf — die Dokumente eines Hauses als geordnetes, belegtes, abfragbares Hauptbuch. Offener Quellcode im Kern, vollständig angepasste Whitelabel-Implementierung.



LOOP-PROTOKOLL

```

> plan()
  Fee · Fonds Alpha · gültig heute

> ontology.query(subject="fonds_alpha")
  3 Entitäten · 11 Events · 214 Buchungen

> rerank(top_k=200, model="ctx-r1")
  12 Passagen aus 214.000

> sub_llm × 8 → fold()
  482.000 Token gelesen · 1.400 behalten

✓ answer.ready = True
  „1,5 % p. a.“ · LPA 2024 § 6.2
  
```

EIN DURCHLAUF

482.000 Token gelesen

Prompt-Ära		Kontextrot
RLM-Loop		flach

Gleiche Arbeit, gleiche Frage. Der eine Kontext läuft voll und verliert die Mitte. Der andere bleibt flach — und kann weiterlaufen.

Die Prompting-Ära ist vorbei.

Drei Jahre lang war die Antwort auf jedes Problem ein besserer Prompt. Dokumente wurden in ein Kontextfenster geklebt, eine Instruktion darüber geschrieben, und dann wurde gehofft. Das funktioniert, solange die Fragen klein sind. Bei einem Fonds sind sie es nie: Die Frage nach einer Management Fee berührt den Gesellschaftsvertrag, drei Nachträge, zwei Side Letter, achtzehn Kontoblätter — und die Frage, welche Fassung heute gilt.

Die Kontextfenster sind gewachsen, das Problem ist mitgewachsen. Die Kosten steigen linear mit der Länge, die Trefferquote fällt. Kontextrot heißt der Effekt: Ein Modell, das eine Million Token liest, erinnert am Ende Anfang und Schluss und verliert die Mitte. In der Mitte steht die abgelöste Fassung.

Was stattdessen kommt, ist ein Loop. Das Modell bekommt die Daten nicht mehr in den Kontext gelegt, sondern in die Hand: Es fragt die Ontologie ab, ruft den Reranker, liest die Treffer, faltet den Rest wieder weg — und beginnt von vorn, bis die Antwort steht.

Rekursiv heißt dabei nichts Mystisches. Das Modell startet frische Kopien seiner selbst und schickt sie los, um zu lesen, was es nicht im eigenen Kopf haben will: acht Kontoblätter, ein Vertragswerk, ein PDF mit vierhundert Seiten. Zurück kommen nicht die Seiten, sondern das Ergebnis. Das Modell ruft sich selbst auf — deshalb rekursiv. Und weil sein Kontext dabei kurz bleibt, kann es weiterarbeiten, wenn ein Ein-Prompt-System längst voll gelaufen ist.

■ Nicht mehr Kontext ins Modell. Sondern dem Modell einen Ort geben, an dem der Kontext bereits geordnet liegt.

DER LOOP

Was ein Loop ist — und was ihn zu verwalten heißt.

Ein Loop ist kein Chat. Ein Agent im Loop durchläuft dieselbe Arbeit wieder und wieder — arbeiten, prüfen, korrigieren, weitermachen — bis eine Abbruchbedingung erfüllt ist. Zwischen den Durchläufen tippt niemand. Die eigentliche Arbeit verschiebt sich damit: Sie besteht nicht mehr darin, den nächsten Prompt zu formulieren, sondern darin, den Loop zu bauen. Was löst ihn aus, woran prüft er sich, wann hört er auf.

Ein Prompt ist ein Satz. Ein Loop ist ein System. Und Loops unterscheiden sich vor allem danach, was man aus der Hand gibt.

VIER BAUFORMEN

Turn-basiert

AUS DER HAND GEGEBEN

die Prüfung

AUSGELÖST DURCH

eine gestellte Aufgabe

ENDET

wenn der Agent die Arbeit für erledigt hält

WOFÜR

kurze, offene Aufgaben, bei denen jemand mitliest

Ziel-basiert

AUS DER HAND GEGEBEN

die Abbruchbedingung

AUSGELÖST DURCH

den vorherigen Durchlauf

ENDET

wenn eine unabhängige Prüfung das Ziel bestätigt — oder die Durchlaufgrenze greift

WOFÜR

Aufgaben mit einem prüfbaren „fertig“

Zeit-basiert

AUS DER HAND GEGEBEN

der Auslöser

AUSGELÖST DURCH

ein Intervall

ENDET

wenn abgebrochen wird oder die beobachtete Arbeit fertig ist

WOFÜR

wiederkehrende Arbeit, Warten auf äußere Zustände

Proaktiv

AUS DER HAND GEGEBEN

die Aufgabe selbst

AUSGELÖST DURCH

ein Ereignis oder einen Plan

ENDET

wenn der Betrieb ihn abschaltet

WOFÜR

feste Ströme: Posteingang, Abstimmung, Migration

Loop-Management ist die Disziplin, die daraus entsteht, und sie besteht im Kern aus drei Fragen.

Erstens: Woran erkennt der Loop, dass seine Arbeit richtig ist? Ohne verlässliche Prüfung ist ein Loop nur eine Maschine, die ihre Fehler wiederholt – schnell und unermüdlich. Zweitens: Was hält ihn an? Abbruchbedingungen, Durchlaufgrenzen, Budgets, Kontrollpunkte; ohne sie läuft er, bis das Budget alle ist. Drittens: Woraus schöpft er? Kodifiziertes Fachwissen statt Erklärungen bei jedem Lauf, getrennte Arbeitsbereiche für parallele Agenten, Unteragenten für abgegrenzte Teilaufgaben, ein Zustand, der zwischen den Durchläufen bestehen bleibt.

Die erste Frage ist die schwerste – und sie ist der Grund, warum diese Schicht existiert. Ein Loop darf nur unbeaufsichtigt laufen, wenn er sein eigenes Ergebnis prüfen kann. In einem Fonds heißt geprüft nichts Vages: Die Buchung hat zwei Beine, die sich schließen. Der Betrag steht in einem Dokument, mit Seite und Absatz. Die Fassung, aus der er stammt, ist die heute gültige. Der Vorgang ist vollständig – kein Kapitalabruf ohne Gegenbuchung, keine Bewertung ohne Periode.

Genau diese Fragen kann eine Ontologie beantworten und ein Dokumentenhaufen nicht. Die Context-Layer ist deshalb nicht nur die Datenquelle des Loops. Sie ist seine Prüfinstanz – und damit die Bedingung dafür, dass er überhaupt allein laufen darf.

Eine Schicht unter allen Funktionen.

Fondsbetrieb zerfällt in Funktionen: Kapitalabrufe, Bewertung, Abstimmung, Reporting, Steuer, Compliance. Jede hat historisch ihre eigene Ablage, ihre eigene Wahrheit, ihre eigene Tabelle. Die Context-Layer liegt quer darunter — vier Schichten tief, für jede Funktion dieselbe Grundlage. Sie ist kein Chatbot und kein Suchfeld, sondern der Boden, auf dem beides erst steht.

Fondsbetrieb

IN DER EIGENEN ANWENDUNG

Kapitalabrufe

NAV & Bewertung

Cash & Abstimmung

Investorenreporting

Steuer & Abschluss

Compliance & Audit

Die Context-Layer

EINE SCHICHT, QUER ÜBER ALLE FUNKTIONEN

01 Context-Loop

LOOP

Der Agent bekommt keinen Prompt, sondern einen Loop: planen, fragen, ranken, falten.

plan ontology.query rerank sub_llm fold

02 Retrieval

PRÄZISION

Erste Stufe holt breit, der eigens trainierte Cross-Encoder entscheidet, was oben steht.

Trigram BM25 Vektor Cross-Encoder auf eigenen Daten

03 Ontologie

BEDEUTUNG

Aus Dokumenten werden Sätze mit Subjekt und Objekt — ein Hauptbuch, kein Haufen Chunks.

Entitäten Events Buchungen Kennzahlen Belege

04 Aufnahme

QUELLE

Alles, was hereinkommt, wird ein Dokument mit Seite, Zeile und Zeitstempel.

Posteingang

Portale

Banken

Ordner-Sync

OCR

Keine Funktion bekommt ihre eigene Ablage. Alle greifen auf dieselben Daten, dieselben Belege, dieselbe Gültigkeit.

Ein Hauptbuch, kein Haufen Chunks.

Jeder RAG-Prototyp der letzten Jahre endete an derselben Stelle: Dokumente in Stücke schneiden, Stücke in Vektoren verwandeln — und dann feststellen, dass „250.000 EUR“ in einem Vektorraum keine Richtung hat. Ein Betrag ohne Subjekt, ohne Gegenpartei, ohne Datum ist keine Information. Er ist eine Zahl auf Papier.

Deshalb ist die zweite Schicht keine Vektordatenbank, sondern ein Hauptbuch. Jede Aussage bekommt eine Grammatik: wer, gegenüber wem, wann, wie viel — hin und zurück, denn jede Buchung hat zwei Beine. Darüber liegen Vorgänge, die zusammengehörende Buchungen klammern, Gruppen, die aus mehreren Gesellschaften ein Asset machen, und Kennzahlen mit Periode und Szenario. Und unter allem bleibt der Beleg.

EVENT

Kapitalabruf

type drawdown · 2024-12-17

KLAMMERT

TRANSACTION

OUTFLOW

-250.000,00 EUR

INFLOW

250.000 fund_interest

status reconciled · Meldewährung EUR

SUBJECT

OBJECT

LEGAL_ENTITY

Holding Beta GmbH

type holding · legal_form GmbH

ENTITY_GROUP · ASSET ALPHA

LEGAL_ENTITY

Fonds Alpha KG

type fund · legal_form KG

+ Zahlungskonto, + Objektgesellschaft

HANDELT VON

MEASUREMENT

NAV · 12.400.000 EUR

period Q4 2024 · scenario actual

BELEG Kapitalabruf_2024-12.pdf · S. 1 · § 2

Jeder Knoten in diesem Bild hängt an einer Fundstelle. Kein Wert existiert ohne das Dokument, aus dem er stammt.

Fünf Satzarten

legal_entity WER UND WAS	Fonds, Gesellschaft, Person, Konto, Objekt. Alles, was Subjekt oder Gegenpartei sein kann.
entity_group WAS ZUSAMMENGEHÖRT	Ein Asset besteht selten aus einer Entität. Die Gruppe bündelt Objektgesellschaft, Konto und Beteiligung zu einer Sache, über die man sprechen kann.
event DER ANLASS	Der Kapitalabruf, die Bewertung, die Ausschüttung. Klammert die Buchungen, die zu einem Vorgang gehören.
transaction WAS FLOSS	Zwei Beine — Abfluss und Zufluss. Das Vorzeichen ist die Richtung, die Meldewährung ist immer dabei.
measurement WIE ES STEHT	NAV, Umsatz, EBITDA, Fair Value — mit Periode, Szenario und Instrument, nicht als freier Text.

Das ist der Teil, den man nicht von der Stange kauft und der nicht generisch sein kann. Ein Family Office bucht anders als ein Dachfonds, eine KG anders als eine Holding. Die Ontologie wird auf das jeweilige Haus ausgeprägt: dieselbe Grammatik, eigenes Vokabular.

Und weil sie eine Grammatik ist, ist sie abfragbar. Ein Agent muss nicht 214.000 Passagen lesen, um zu wissen, was Fonds Alpha 2024 abgerufen hat. Er stellt eine Frage an das Hauptbuch und bekommt 214 Zeilen. Das ist der Unterschied zwischen einem Modell, das sucht, und einem Modell, das weiß.

Ein Reranker, der die Sprache des Hauses spricht.

Die erste Stufe jedes Retrievals ist auf Vollständigkeit optimiert: BM25 für exakte Begriffe, Trigram für Schreibvarianten und OCR-Rauschen, Vektorsuche für Paraphrasen. Sie liefert breit — und in grober Reihenfolge, denn keine dieser Methoden versteht die Frage.

Die zweite Stufe entscheidet. Ein Cross-Encoder liest Frage und Textstelle gemeinsam, jedes Wort der Frage sieht jedes Wort der Passage, heraus kommt ein kalibrierter Score. Die Modelle von der Stange sind auf Web-Korpora trainiert; für Finanzdeutsch ist das doppelt falsch. Kapitalerhöhungsbeschluss zerfällt im Tokenizer, Kapitalkonto II liegt außerhalb der Trainingsverteilung — und dass die Fassung von 2021 abgelöst ist, sieht ein Web-Modell nicht: Sie ist zu ihrer Nachfolgerin nahezu tokengleich.

Also wird eines auf den Beständen selbst trainiert: den Verträgen, Kontoblättern, Side Lettern des Hauses. Die Trainingspaare kommen aus der Ontologie, die Hard Negatives aus abgelösten Fassungen und Zwillingspassagen — genau den Fällen, an denen generische Modelle plausibel und falsch ranken. Klein genug für den heißen Pfad: einstellige Millisekunden, bei jedem getippten Wort.

In der Praxis liest niemand zehn Treffer. Gelesen wird der erste. Ob ein System Vertrauen aufbaut oder verspielt, entscheidet sich genau dort.

Und es bleibt nicht stehen.

Jeder Loop-Durchlauf hinterlässt Signal. Welche Passage die Antwort getragen hat und welche danebenlag. Welche Fassung sich als die gültige erwiesen hat. Wo eine Korrektur nötig war und woran sie hing. Wo eine Buchung sich nicht schloss und welches Dokument sie am Ende schloss.

Ein Loop läuft

→

Belegte Treffer und Korrekturen werden
Signal

→

Signal wird zu Trainingspaaren

→

Das nächste Rerank-Modell entsteht

🔄 und der schärfere Reranker erzeugt wieder saubereres Signal

Aus diesem Signal werden Trainingspaare: die belegten Treffer als Positive, die knapp verfehlten Zwillinge als Hard Negatives. Auf ihnen entsteht die nächste Generation des Rerankers — und die trifft genau dort besser, wo zuletzt danebengegriffen wurde. Das Retrieval ist damit kein eingekauftes Bauteil, sondern ein Mechanismus, der sich selbst nachschärft.

So schließt sich der Kreis, und er schließt sich nach innen: Der Loop fragt das Retrieval, das Retrieval wird aus dem Loop besser, der bessere Loop erzeugt saubereres Signal. Was dabei entsteht, ist kein Produkt aus dem Regal, sondern ein eigenes Gefüge aus Daten, Loops und Retrieval-Mechanik — gewachsen an einem Ort, und nur dort so wirksam.

Top-1

die einzige Position, die im Alltag zählt

< 10 ms

Reranking im Latenzbudget der Suche

Eigene Gewichte

trainiert auf den Beständen des Hauses, nicht auf dem Web

Was angepasst wird, und was mitkommt.

Der Quellcode ist offen, die Implementierung wird auf das jeweilige Haus zugeschnitten, und nach vorn tritt die Anwendung des Betreibers. Die Kundenbeziehung bleibt dort, wo sie hingehört. Was darunter liegen soll, ist die beste Datenschicht des deutschsprachigen Fondsmarkts.

Angepasst

- Marke, Domain, Oberfläche
- Workflows und Freigaben
- Ontologie und Vokabular
- Modellgewichte des Rerankers
- Betriebsort — eigene Cloud oder unsere

Mitgeliefert

- Aufnahme, Konvertierung, Extraktion
- Index, Embeddings, Reranking
- Der Context-Loop und seine API
- Betrieb, Monitoring, SLA
- Die Forschung dahinter

Ein Bestand trainiert ein Modell und sonst keines. Keine geteilten Embeddings, keine geteilten Gewichte, kein Training über fremde Bestände hinweg.

Wer die Context-Layer hat, hat die Antwort.

Die Modelle werden austauschbar. Sie werden jedes Jahr besser, billiger und einander ähnlicher, und niemand wird sich in fünf Jahren daran erinnern, welches man 2026 genommen hat.

Was nicht austauschbar wird, ist das Gefüge darunter: geordnete, belegte, abfragbare Daten; Loops, die sich an diesen Daten prüfen können und deshalb allein laufen dürfen; und ein Retrieval, das aus jedem Durchlauf schärfer wird. Die drei halten einander fest — jedes Teil macht die anderen besser.

So etwas entsteht nur einmal, es entsteht dort, wo die Dokumente liegen, und es lässt sich nicht kaufen. Das ist der Graben.

Kontakt

Die Context-Layer ist im Aufbau. Für Häuser, die eine Implementierung erwägen, lohnt ein frühes Gespräch — die Ontologie entsteht mit den Dokumenten, nicht danach.

cd@fundops.de

[Über uns / Impressum](#) [Datenschutz](#)